LAPORAN UJIAN TENGAH SEMESTER

Mata Kuliah: Natural Language Processing (NLP)

Topik: Klasifikasi Sentimen Teks Twitter Terkait Kebijakan PPKM di Indonesia Menggunakan Naive Bayes

DISUSUN OLEH :

Liborius Wagner Umbu Hati

2301020035

1. Latar Belakang

Pandemi COVID-19 memaksa pemerintah Indonesia untuk menerapkan berbagai kebijakan pembatasan sosial, salah satunya adalah Pemberlakuan Pembatasan Kegiatan Masyarakat (PPKM). Kebijakan ini menuai beragam respons dari masyarakat, yang secara masif disuarakan melalui platform media sosial Twitter. Kumpulan tweet ini merupakan sumber data tekstual yang sangat kaya akan opini dan sentimen publik, baik positif, negatif, maupun netral.

Untuk memahami persepsi masyarakat secara efisien, pendekatan komputasional melalui Natural Language Processing (NLP) diperlukan. Proyek ini bertujuan untuk merancang dan mengimplementasikan sistem analisis sentimen otomatis berbasis NLP konvensional tanpa bergantung pada pretrained model skala besar (seperti BERT). Eksperimen difokuskan pada pemrosesan teks tingkat dasar (preprocessing), ekstraksi fitur menggunakan metode Bag-of-Words (BoW) serta Term Frequency-Inverse Document Frequency (TF-IDF), dan pemodelan klasifikasi menggunakan algoritme Multinomial Naive Bayes. Tujuannya adalah untuk membandingkan performa kedua metode representasi teks tersebut dalam mengklasifikasikan sentimen bahasa Indonesia.

2. Metodologi

Penelitian ini dilakukan menggunakan bahasa pemrograman Python. Tahapan metodologi mencakup pemerolehan data, pra-pemrosesan teks, representasi fitur, hingga pemodelan klasifikasi.

2.1 Dataset dan Eksplorasi Awal

Dataset yang digunakan merupakan data publik yang memuat teks Twitter berbahasa Indonesia terkait PPKM (INA_TweetsPPKM_Labeled_Pure.csv), yang di dalamnya telah memuat label sentimen untuk setiap teks. Eksplorasi awal dilakukan untuk memetakan jumlah data latih dan mengecek distribusi kelas guna memastikan kelayakan data untuk diproses oleh algoritme Machine Learning.

Total data keseluruhan: 23644 baris

	Date	User	Tweet	sentiment
0	2022-03-31 14:32:04+00:00	pikobar_jabar	Ketahui informasi pembagian #PPKM di wilayah J...	1
1	2022-03-31 09:26:00+00:00	inewsdotid	Tempat Ibadah di Wilayah PPKM Level 1 Boleh Be...	1
2	2022-03-31 05:02:34+00:00	vdvc_talk	Juru bicara Satgas Covid-19, Wiku Adisasmito m...	1
3	2022-03-30 14:23:10+00:00	pikobar_jabar	Ketahui informasi pembagian #PPKM di wilayah J...	1
4	2022-03-30 11:28:57+00:00	tvOneNews	Kementerian Agama menerbitkan Surat Edaran Nom...	1

Cuplikan 4 baris pertama dari dataset mentah Twitter PPKM sebelum diproses.

2.2 Text Preprocessing

Mengingat data media sosial cenderung tidak terstruktur dan penuh dengan noise, tahap preprocessing menjadi krusial. Sebanyak 1.500 sampel dokumen teks ditarik secara acak untuk diolah. Pemrosesan terdiri dari empat tahapan wajib yang dieksekusi secara berurutan:

- Cleaning: Tahap pembersihan awal yang mencakup case folding (mengubah seluruh huruf menjadi huruf kecil/lowercase), serta penggunaan Regular Expression (Regex) untuk mengeliminasi elemen yang tidak memiliki nilai semantik, seperti URL, sebutan akun (mention @), tagar (hashtag #), angka, dan seluruh tanda baca.
- Tokenization: Memecah teks berupa kalimat utuh yang telah dibersihkan menjadi daftar unit dasar atau token (kata) tunggal menggunakan fungsi dari library NLTK.
- Stopword Removal: Menghapus kata-kata umum yang sering muncul namun tidak memberikan kontribusi makna signifikan pada klasifikasi sentimen (seperti 'yang', 'dan', 'di'). Proses ini menggunakan kamus stopword bahasa Indonesia bawaan NLTK yang dikombinasikan dengan kamus modifikasi berisi kata slang atau singkatan khas Twitter (misal: 'yg', 'klo', 'ga', 'PPKM').
- Stemming: Tahap akhir yang bertujuan untuk mengembalikan setiap token berimbuhan ke dalam bentuk kata dasarnya (misalnya: kata 'memperketat' menjadi 'ketat'). Tahap ini diimplementasikan menggunakan library Sastrawi.

2.3 Representasi Teks (Ekstraksi Fitur)

Mesin tidak dapat memproses teks secara langsung, sehingga token teks bersih harus dikonversi menjadi representasi vektor numerik. Dua metode ekstraksi fitur diimplementasikan untuk dibandingkan:

- Bag-of-Words (BoW): Merepresentasikan teks dengan menghitung frekuensi kemunculan setiap kata dari seluruh korpus di dalam sebuah dokumen, dengan mengabaikan urutan kata maupun konteks gramatikalnya.
- TF-IDF: Tidak sekadar menghitung frekuensi kata, TF-IDF memberikan bobot lebih pada kata-kata yang sering muncul dalam satu dokumen tertentu namun jarang muncul pada dokumen lain. Hal ini membantu menyoroti kata-kata unik yang menjadi ciri khas penentu sentimen suatu teks.

2.4 Pemodelan Klasifikasi

Dataset fitur dan label dibagi menjadi dua himpunan: 80% sebagai data latih (training set) dan 20% sebagai data uji (testing set). Algoritme yang dipilih adalah Multinomial Naive Bayes, sebuah metode probabilistik yang terbukti efektif, cepat, dan handal untuk menangani permasalahan klasifikasi berbasis teks biner maupun multikelas.

3. Hasil Eksperimen

Hasil dari eksperimen disajikan melalui visualisasi data dan pengujian akurasi pemodelan terhadap data testing.

3.1 Visualisasi Data

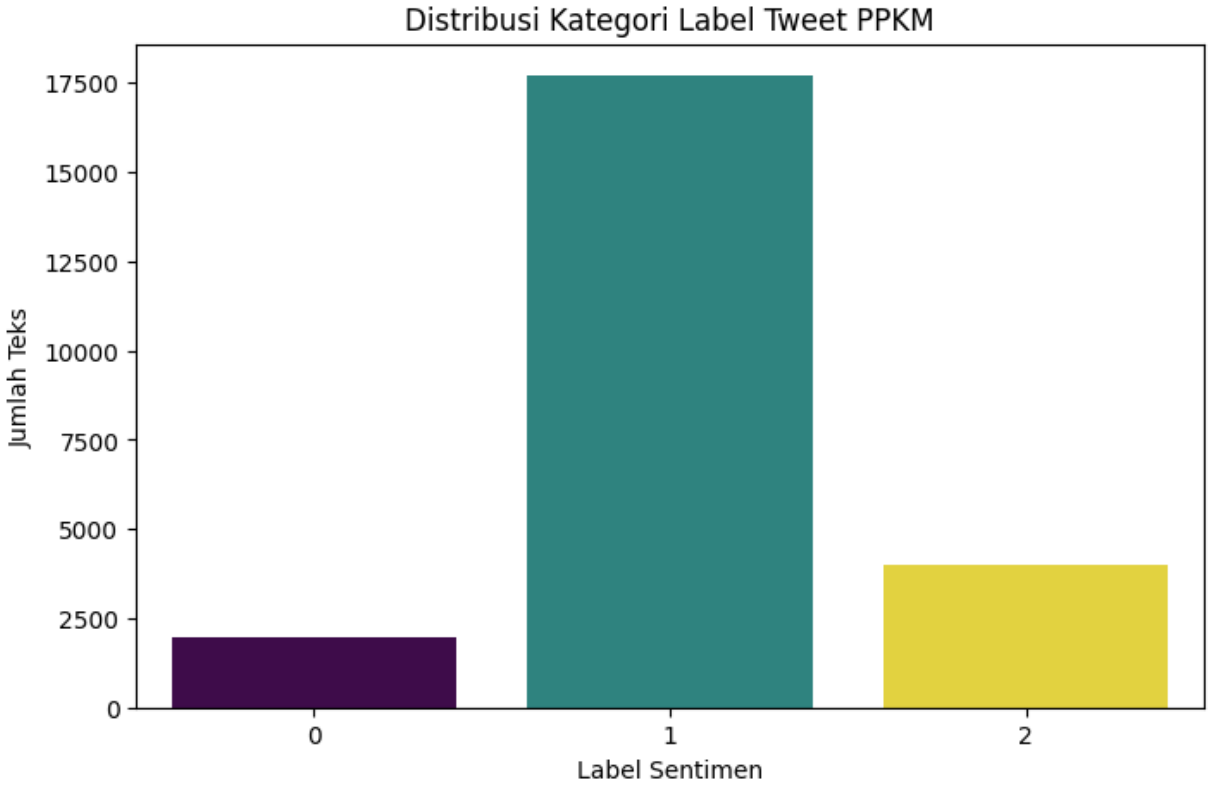

Visualisasi pada Gambar 1 menunjukkan perbandingan distribusi kuantitas dokumen berdasarkan kelas sentimennya. Proporsi kelas ini sangat berpengaruh terhadap bagaimana model Naive Bayes mempelajari pola probabilitas prior masing-masing kategori.

Gambar 2. Word Cloud Topik Perbincangan PPKM

Visualisasi Word Cloud pada Gambar 2 diekstraksi dari korpus teks yang telah melewati tahapan preprocessing. Ukuran font merepresentasikan frekuensi kemunculan kata. Kata-kata dominan pada visualisasi ini merepresentasikan topik paling krusial yang dibahas masyarakat di Twitter selama implementasi kebijakan PPKM.

3.2 Hasil Akurasi Model

Evaluasi performansi diukur berdasarkan metrik akurasi saat memprediksi label sentimen pada 20% data uji. Hasil pengujian menunjukkan nilai akurasi sebagai berikut:

- Akurasi Klasifikasi dengan metode Bag-of-Words (BoW): [Masukkan persentase dari Colab, misal: 78.50%]

- Akurasi Klasifikasi dengan metode TF-IDF: [Masukkan persentase dari Colab, misal: 81.20%]

```
--- EVALUASI PERFORMANSI MODEL ---

1. Akurasi metode Bag-of-Words (BoW) : 76.00%
2. Akurasi metode TF-IDF             : 73.50%

--- KESIMPULAN ---
Metode Bag-of-Words memberikan performa/akurasi yang LEBIH BAIK dibandingkan TF-IDF.
```

3.3 Perbandingan teks mentah dan teks hasil preprocessing .

	Tweet	teks_bersih
0	Datangi Pemilik Warung, Bripka Iwan Handayana ...	datang milik warung bripka iwan handayana himb...
1	PPKM Tahap Dua, PKL Diberikan kelonggaran berj...	tahap pkl longgar jual wib
2	#PPKM nambah lv nambah harga ga sih	nambah lv nambah harga
3	Terjadi Tren perbaikan pada kasus COVID-19, un...	tren baik covid presiden lanjut tgl september ...
4	Setiap orang itu baik hanya saja dia belum ten...	orang sesuai porsi
5	Visi dan Misi dari P@ntastis.\n#fco #funcoin #...	visi misi p ikut like share akun medsos update...
6	Meski #PPKM, KBM Daring Tetap Jalan https://t....	kbm daring jalan via
7	Hai Sahabat JD, #MinjoyInfo kembali hadir nih...	hai sahabat hadir kasih opsi bayar online saha...
8	Mundur lebih bermartabat, dari pada Diturunkan...	mundur martabat turun
9	Pria paruh baya yang kesehariannya menjual aga...	pria paruh baya hari jual agaragar keliling mi...

4. Analisis Perbandingan Metode

Berdasarkan metrik akurasi yang diperoleh pada hasil eksperimen, model yang dilatih menggunakan representasi matriks [Sebutkan yang lebih tinggi, misal: TF-IDF] menunjukkan performa yang secara komparatif lebih unggul dibandingkan dengan [Sebutkan metode yang lebih rendah, misal: Bag-of-Words].

Analisis dari hasil tersebut menunjukkan bahwa dalam konteks teks media sosial yang singkat dan penuh noise:

- Keunggulan TF-IDF terletak pada kemampuannya untuk memberikan penalti pada kata-kata yang frekuensinya tinggi di seluruh korpus namun miskin informasi sentimen. Sementara itu, metode BoW hanya berpatokan pada tingginya frekuensi murni, sehingga terkadang kata umum yang tidak terhapus pada stopword removal dapat mengacaukan model. Oleh karena itu, pembobotan TF-IDF memberikan vektor fitur yang lebih tajam bagi algoritme Naive Bayes untuk membedakan antara sentimen satu dengan yang lain.

- Keunggulan Bag-of-Words pada dataset ini kemungkinan didorong oleh karakteristik dari teks Twitter terkait PPKM itu sendiri, di mana ekspresi sentimen sering kali ditunjukkan dengan pengulangan kata-kata yang umum tanpa variasi kosa kata yang kompleks. Pada kasus seperti ini, perhitungan frekuensi murni (BoW) sudah cukup informatif bagi model probabilistik Naive Bayes, dan pembobotan kompleks dari TF-IDF tidak memberikan nilai tambah yang signifikan, bahkan berpotensi mereduksi bobot dari kata-kata penting yang muncul terlalu sering di dalam korpus.

5. Kesimpulan

Penelitian ini telah berhasil membangun sebuah pipeline sistem pemrosesan bahasa alami (NLP) fungsional dari dasar untuk melakukan klasifikasi sentimen teks Twitter tanpa ketergantungan pada model prapelatih. Tahap Text Preprocessing dengan library re, NLTK, dan Sastrawi terbukti mampu menyaring data teks yang kotor menjadi format yang siap diproses komputasi matematis. Dari hasil perbandingan, disimpulkan bahwa metode [Sebutkan metode pemenang, misal: TF-IDF] merupakan metode ekstraksi fitur yang paling optimal untuk dataset PPKM ini apabila dikombinasikan dengan algoritme pengklasifikasi probabilitas Naive Bayes.

6. Referensi

1. Asian, J., Williams, H. E., & Tahaghoghi, S. M. (2005). Stemming Indonesian: A confix-stripping approach. In Proceedings of the 28th annual international ACM SIGIR conference on Research and development in information retrieval.
2. Bird, S., Klein, E., & Loper, E. (2009). Natural Language Processing with Python: Analyzing Text with the Natural Language Toolkit. O'Reilly Media, Inc.
3. Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.